

Informe Teórico Practico 1

Fundamentos de Aprendizaje Automático

Germán A. Montoya O.
gamontoyao@eafit.edu.co

Universidad EAFIT

Medellín 2026

Informe Teórico Practico 1

- Se puede entregar en grupos de máximo 3 personas.
- **Entregables:**
 - **Dos archivos:**
 - El *.ipynb
 - El pdf del *.ipynb

Informe Teórico Practico 1

- **Acercas del uso de IA:**

- Se puede usar como apoyo para el código fuente de todo el proyecto.
 - **Nota:** recuerde que la idea es que ud como estudiante entienda qué realiza y el por qué de usar un determinado comando o instrucción.
- Dado que las IAs ahora incluyen marca de agua, las descripciones, justificaciones, explicaciones, análisis o conclusiones deben ser escritas con sus propias palabras y NO por la IA. El uso de IA en alguno de estos apartados reducirá la nota en un 60%.

Informe Teórico Practico 1

- **Contenido del proyecto:**

- **Negocio y dataset:**

- Describir y justificar el problema/negocio, así como el contexto del mismo.
 - Justificación del dataset: argumentar los motivos por los cuales analizar el dataset podría ser beneficioso para aportar a la solución del problema.
 - Describir de donde se obtuvo.
 - ¿Qué tipo de predicción deseamos hacer? (¿Es una clasificación o una regresión?).
 - Clasificación: predecir categorías.
 - Regresión: predecir un número continuo.
 - ¿Qué queremos que el modelo prediga exactamente? (Ej: Predecir si un correo es SPAM o no; si una persona va a estar sana o enferma, entre otros.).

Informe Teórico Practico 1

- Posibles webs para buscar datasets:
 - <https://www.kaggle.com/datasets>
 - <https://ieee-dataport.org/datasets>
 - <https://mlcontests.com/>
 - <https://www.datos.gov.co/>
 - <https://medata.gov.co/search/>

Informe Teórico Practico 1

- **Contenido del proyecto:**
 - **Limpieza, preprocesamiento y EDA:**
 - Particionar adecuadamente el dataset para evitar el Data Leakage (Fuga de Datos).
 - Realice todas las actividades de limpieza que consideren necesarias en las particiones previas.
 - Realice actividades de codificación de columnas (one hot, label, binary encoding). Recuerde que la idea es que el dataset sea totalmente numérico. Justifique las decisiones tomadas.
 - Realice actividades de posible eliminación de columnas (Correlación y Multicolinealidad). Justifique las decisiones tomadas.
 - Realice actividades de escalamiento (Max-Min Scaling, StandarScaler, RobustScaler, $\log(x)$). Justifique las decisiones tomadas.

Informe Teórico Practico 1

- **Contenido del proyecto:**

- **Limpieza, preprocesamiento y EDA:**

- Analice cómo se comportan los datos usando EDA manualmente. Haga uso de:
 - Medidas de tendencia central, de dispersión y posición.
 - Obtenga el IQRratio y analice si la columna puede brindar información o no para el modelo predictivo. Justifique las decisiones tomadas.
 - Apoyese en histogramas u otras visualizaciones para analizar gráficamente los datos. Justifique las decisiones tomadas.
 - Compare el EDA manual con el EDA automático visto en clase. Comparelos y justifique similitudes y diferencias.

Informe Teórico Practico 1

- **Contenido del proyecto:**

- **Aplicación de un modelo predictivo:**

- **Sobre el dataset “sucio”:** Tome el dataset original y límpielo minimamente para que un modelo predictivo escogido arroje su desempeño.
 - **Nota:** debe estar mínimamente limpio, ya que de otro modo muy probablemente el modelo arrojaría un error de compilación.
 - **Sobre el dataset limpio:** Tome el dataset limpio, preprocesado y analizado para que le aplique el mismo modelo del dataset “sucio”. Debería obtener un ligero mejor desempeño.
 - Analice y concluya sobre el desempeño obtenido entre el dataset sucio y el limpio.
 - Redacte conclusiones generales de todo el proyecto.